

KOCAELİ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

LİSANS TEZİ

**İnsansız Hava Araçları (İHA) Görüntülerinden Derin Öğrenme Tabanlı
İnsan Tespiti**

YUNUS EMRE ARI

KOCAELİ 2026

KOCAELİ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

ARAŞTIRMA PROBLEMLERİ

İnsansız Hava Araçları (İHA) Görüntülerinden Derin Öğrenme Tabanlı
İnsan Tespiti

YUNUS EMRE ARI - 230201096

KOCAELİ 2026

KOCAELİ ÜNİVERSİTESİ

ÖNSÖZ VE TEŞEKKÜR

Bu tez çalışması, afet sonrası arama-kurtarma faaliyetlerinde ve güvenlik uygulamalarında kullanılmak üzere, İnsansız Hava Araçları (İHA) görüntülerinden derin öğrenme tabanlı otonom insan tespiti yapan bir sistemin geliştirilmesi ve bu sayede arama süreçlerinin hızlandırılması amacıyla gerçekleştirilmiştir.

Tez çalışmamda desteğini esirgemeyen, çalışmalarına yön veren, bana güvenen ve yüreklendiren danışmanım Sayın Dr. Öğr. Üyesi Fidan KAYA GÜLAĞIZ’a sonsuz teşekkürlerimi sunarım.

Hayatım boyunca bana güç veren en büyük destekçilerim, her aşamada sıkıntılarımı ve mutluluklarımı paylaşan sevgili aileme teşekkürlerimi sunarım.

Ocak – 2026

Yunus Emre ARI

İÇİNDEKİLER

ÖNSÖZ VE TEŞEKKÜR	i
ŞEKİLLER DİZİNİ.....	iii
SİMGELER VE KISALTMALAR DİZİNİ	iv
ÖZET.....	v
ABSTRACT.....	vi
GİRİŞ	1
1. LİTERATÜR TARAMASI VE KURAMSAL ÇERÇEVE.....	4
1.1. İnsansız Hava Araçları ve Görüntü İşleme.....	4
1.2. Derin Öğrenme ve Nesne Tespiti Temelleri.....	6
1.2.1. Konvolüsyonel sinir ağları (CNN) mantığı	6
1.2.2. İki aşamalı (two-stage) ve tek aşamalı (One-Stage) modeller.....	7
1.3. YOLO Algoritması ve Gelişimi	7
1.3.1. YOLO'nun çalışma prensibi.....	8
1.3.2. YOLOv1'den YOLOv8'e gelişim süreci	8
1.3.3. Neden YOLO tercih edildi?.....	9
1.4. Küçük Nesne Tespiti (Small Object Detection) Problemi	9
1.4.1. Literatürdeki temel zorluklar	10
1.4.2. VisDrone Veriseti ve Önemi	10
2. MATERYAL VE YÖNTEM.....	11
2.1. Veri Seti (VisDrone2019-DET)	11
2.2. Kullanılacak Model Mimarisi (YOLOv8).....	12
2.3. Eğitim Stratejisi ve Donanım	14
2.4. Başarı Ölçütleri (Metrikler).....	15
3. BEKLENEN SONUÇLAR VE TARTIŞMA	17
3.1. Test Senaryoları.....	17
3.2. Beklenen Performans Analizi.....	17
3.3. Karşılaştırma Planı	18
4. SONUÇ VE ÖNERİLER.....	20
KAYNAKLAR	22
ÖZGEÇMİŞ	25

ŞEKİLLER DİZİNİ

Şekil 1.1.	İHA bakış açısından arama-kurtarma operasyonu görünümü	5
Şekil 1.2.	Genel Konvolüsyonel Sinir Ağı (CNN) mimarisi ve katman yapısı	6
Şekil 2.1.	VisDrone2019-DET veri seti kullanılarak oluşturulan örnek etiketli görüntüler	11
Şekil 2.2.	YOLOv8 modelinin katman yapısı ve mimari şeması	13
Şekil 2.3.	Önerilen sistemin genel çalışma akış şeması	14
Şekil 2.4.	Intersection over Union (IoU) hesaplama mantığı	16

SİMGELER VE KISALTMALAR DİZİNİ

%	: Yüzde
@	: At (eşik değeri belirtmek için, örneğin mAP@50'de)

Kısaltmalar

CNN	: Convolutional Neural Network (Evrişimli Sinir Ağı)
FPS	: Frames Per Second (Saniyedeki Kare Sayısı)
GUI	: Graphical User Interface (Grafik Kullanıcı Arayüzü)
İHA	: İnsansız Hava Aracı
IoU	: Intersection over Union (Kesişim Bölü Birleşim)
Loss	: Kayıp Fonksiyonu (Eğitim sırasında modelin hata ölçüsü)
mAP	: mean Average Precision (Ortalama Kesinlik Ortalaması)
MS-COCO	: Microsoft Common Objects in Context (Microsoft Ortak Nesneler Veri Seti)
NMS	: Non-Maximum Suppression (Maksimum Olmayanı Bastırma)
ROI	: Region of Interest (İlgi Alanı / Aday Bölge)
RPN	: Region Proposal Network (Bölge Öneri Ağı)
SAHI	: Slicing Aided Hyper Inference (Dilime Bölme Destekli Hiper Çıkarım)
SPD-Conv	: Space-to-Depth Convolution (Uzaydan Derinliğe Evrişim)
SSD	: Single Shot Detector (Tek Atışlı Tespit Edici)
TensorRT	: TensorRT (NVIDIA'nın yüksek performanslı çıkarım optimizasyon kütüphanesi)
VisDrone	: Vision Meets Drone (İHA odaklı nesne tespiti benchmark veri seti)
YOLO	: You Only Look Once (Sadece Bir Kez Bak)

İNSANSIZ HAVA ARAÇLARI GÖRÜNTÜLERİNDEN DERİN ÖĞRENME TABANLI GERÇEK ZAMANLI İNSAN TESPİTİ İÇİN YAKLAŞIMLAR VE YÖNTEM ANALİZİ

ÖZET

Bu çalışmanın amacı, afet yönetimi ve arama-kurtarma faaliyetlerinde kullanılmak üzere İnsansız Hava Araçları (İHA) görüntülerinden gerçek zamanlı ve otonom insan tespiti yapabilen derin öğrenme tabanlı bir sistem mimarisi geliştirmektir. Artan veri boyutlarının manuel analizindeki zorluklar ve operatör yorgunluğu sorununa çözüm olarak, CNN tabanlı nesne tespit algoritmaları karşılaştırmalı olarak incelenmiştir. Donanım kısıtları ve anlık tepki gereksinimleri doğrultusunda, işlem hızı ve doğruluk dengesi açısından en uygun yöntemin YOLO mimarisi olduğu belirlenmiştir.

Çalışmada, İHA görüntülerine özgü küçük nesne tespiti ve örtüşme problemlerini aşmak amacıyla VisDrone2019-DET veri seti kullanılarak istatistiksel analizler gerçekleştirilmiştir. Yöntem olarak, YOLOv8 tabanlı özelleştirilmiş bir eğitim stratejisi, transfer öğrenme ve veri normalizasyon teknikleri önerilmiştir. Elde edilen bulgular, standart veri setlerinin İHA perspektifinde yetersiz kaldığını göstermiş ve önerilen optimize edilmiş mimarinin, gerçek zamanlı uygulamalar için gereken kesinlik ve duyarlılık performansını sağlayacak altyapıyı oluşturduğunu ortaya koymuştur.

Anahtar Kelimeler: Arama Kurtarma, Derin Öğrenme, İHA, İnsan Tespiti, YOLOv8.

APPROACHES AND METHODOLOGICAL ANALYSIS FOR REAL-TIME HUMAN DETECTION FROM UNMANNED AERIAL VEHICLE IMAGERY BASED ON DEEP LEARNING

ABSTRACT

The aim of this study is to develop a deep learning-based system architecture capable of real-time and autonomous human detection from Unmanned Aerial Vehicle (UAV) imagery for use in disaster management and search and rescue operations. As a solution to the difficulties in manual analysis of increasing data sizes and the problem of operator fatigue, CNN-based object detection algorithms were examined comparatively. In line with hardware constraints and immediate response requirements, it was determined that the YOLO architecture is the most suitable method in terms of the balance between processing speed and accuracy.

In the study, statistical analyses were performed using the VisDrone2019-DET dataset to overcome small object detection and occlusion problems specific to UAV imagery. As a method, a YOLOv8-based customized training strategy, transfer learning, and data normalization techniques were proposed. The obtained findings showed that standard datasets remain insufficient from the UAV perspective and revealed that the proposed optimized architecture establishes the infrastructure to provide the precision and sensitivity performance required for real-time applications.

Keywords: Deep Learning, Human Detection, Search and Rescue, UAV, YOLOv8.

GİRİŞ

Dünya genelinde hem doğal hem de insan eliyle meydana gelen afetlerin sıklığı ve etki alanı son yıllarda dramatik bir artış göstermiştir [15].

Küresel ısınmanın tetiklediği meteorolojik değişimler, jeolojik anomaliler ve endüstriyel kazalar, can kaybı ile birlikte devasa ekonomik ve altyapısal tahribatlara yol açmaktadır [15]. Güç sistemlerinden kentsel yerleşim alanlarına kadar her noktada hissedilen bu yıkıcı etkiler, afet sonrası müdahale süreçlerinin ne kadar kritik olduğunu bir kez daha ortaya koymaktadır. Özellikle bina çökmeleri ve geniş çaplı doğa olayları sonrasında ölüm oranlarının en büyük sebebi, doğrudan afetin kendisinden ziyade, enkaz altında kalan veya kaybolan mağdurlara zamanında ulaşılamamasıdır [15]. Literatürde "altın saatler" olarak adlandırılan ilk 72 saatlik dilim, bir mağdurun sağlık durumunun geri dönülemez şekilde bozulmadan kurtarılması için hayati bir sınırdır [13]. Dolayısıyla, afet yönetiminde başarının temel anahtarı, etkilenen bölgelerden zamanında ve yüksek doğrulukla veri toplayarak arama-kurtarma operasyonlarını derhal başlatabilmektir.

Geleneksel arama-kurtarma yöntemleri büyük ölçüde saha gönüllülerinin fiziksel çabalarına ve manuel veri toplama süreçlerine dayanmaktadır.

Ancak bu yaklaşım, hem kurtarma ekiplerinin hayatını tehlikeye atmakta hem de geniş coğrafi alanlarda son derece yavaş kalmaktadır. Sahadaki gönüllülerin eğitimi, koordinasyonu ve zorlu arazi koşullarında hareket kabiliyetleri, operasyonun başarısını sınırlayan temel faktörlerdir. Bu noktada uzaktan algılama teknolojileri, geniş alanların hızla taranması ve güvenli veri akışı sağlanması için kritik bir çözüm yolu olarak öne çıkmaktadır. Geçmişte bu amaçla kullanılan uydu görüntüleri; bulutluluk gibi hava koşulları, dikey perspektif sınırlamaları ve düşük çözünürlük sorunları nedeniyle operasyonel düzeyde yetersiz kalmıştır. İnsanlı hava araçları ise yüksek maliyetleri ve afet anında bölgeye ulaşım süreleri nedeniyle her zaman pratik bir çözüm sunamamaktadır [15].

Günümüzde İnsansız Hava Araçları (İHA), hızlı konuşlandırılabilen, düşük maliyetli ve yüksek manevra kabiliyetine sahip platformlar olarak arama-kurtarma süreçlerinde merkezi bir işleve sahip hale gelmiştir [15]. Bir İHA, tek bir uçuşta onlarca hektarlık alanı santimetre seviyesinde çözünürlükle tarayabilmekte ve elde ettiği görsel veriyi anlık olarak yer kontrol merkezlerine iletebilmektedir. Bununla birlikte, İHA'ların sağladığı bu devasa veri yığını, beraberinde yeni bir zorluğu da getirmiştir: Manuel izleme ve analiz süreci [13]. Mevcut sistemlerde, İHA'dan gelen yüksek çözünürlüklü görüntülerin uzmanlar tarafından tek tek incelenmesi gerekmektedir. Bir görüntünün kompleks yapısına ve nesne yoğunluğuna bağlı olarak incelenmesi 15 ile 90 saniye arasında sürebilmekte; bu da insan gözünün bir süre sonra yorulmasına, dikkatinin dağılmasına ve dolayısıyla kritik ipuçlarının gözden kaçmasına sebebiyet vermektedir [5, 13]. Özellikle mağdurların küçük bir piksel alanı kapladığı veya çevreyle kamufle olduğu senaryolarda, manuel tespit süreci ciddi hatalara ve zaman kayıplarına gebe dir [5, 15].

Bu eksikliklerin aşılabilmesi için otonom karar verme yeteneğine sahip, derin öğrenme tabanlı tespit sistemlerine ihtiyaç duyulmaktadır. Bilgisayarlı görü ve dijital görüntü işleme alanındaki devrim niteliğindeki gelişmeler, özellikle Evrişimli Sinir Ağları (CNN) aracılığıyla nesne tespitini çok daha güvenilir bir noktaya taşımıştır. CNN mimarileri, görüntüdeki yerel özellikleri hiyerarşik bir yapıda öğrenebildiği için, insan gözünün ayırt etmekte zorlandığı küçük ve karmaşık desenleri yüksek başarıyla tanımlayabilmektedir [15]. Bu projede, özellikle gerçek zamanlı uygulamalarda yüksek hız ve doğruluk dengesi sunan YOLO (You Only Look Once) algoritmasının kullanılması planlanmaktadır. YOLO'nun tek bir ağ üzerinden tüm görüntüyü analiz ederek nesne konumlarını ve sınıflarını belirleyebilmesi, İHA'ların sınırlı donanımsal kaynakları üzerinde otonom tespit yapabilmesine olanak tanımaktadır [15].

Bu tez çalışması kapsamında, İHA görüntülerinden derin öğrenme tabanlı gerçek zamanlı insan tespiti yapabilen özgün bir sistemin geliştirilmesi hedeflenmektedir. Geliştirilmesi planlanan bu sistemin, manuel izleme sürecindeki yavaşlığı ve insan kaynaklı hataları minimize ederek, arama-kurtarma operasyonlarında kaybedilen her bir dakikayı geri kazanması amaçlanmaktadır [15]. Projenin literatüre temel katkısının; afet bölgelerindeki değişken ışık ve hava koşullarına dayanıklı, küçük nesne tespiti performansını artıran modüllerle zenginleştirilmiş ve doğrudan uç

birimlerde (edge computing) çalışabilecek hafifletilmiş bir derin öğrenme modeli sunması olması beklenmektedir. Nihayetinde, bu çalışmanın afet yönetimi teknolojilerinde otonomizasyonu bir adım ileri taşıyarak, can kayıplarının azaltılmasında somut bir mühendislik çözümü sunması hedeflenmektedir [13, 15].

Çalışmanın Amacı Bu projenin temel gayesi, afet sonrası arama-kurtarma faaliyetlerinde İHA'lar aracılığıyla toplanan yüksek çözünürlüklü görsel verileri, derin öğrenme algoritmaları kullanarak otonom bir şekilde analiz etmektir. Hedeflenen sistemin, gerçek zamanlı olarak insan varlığını tespit etmesi ve kurtarma ekiplerine hızlı ve doğru lokasyon verisi sağlaması planlanmaktadır. Bu sayede, manuel görüntü izleme süreçlerindeki gecikmelerin önüne geçilmesi ve müdahale süresinin "altın saatler" içerisinde tutularak hayatta kalma oranlarının artırılması hedeflenmektedir.

1. LİTERATÜR TARAMASI VE KURAMSAL ÇERÇEVE

Bu bölümde, tez çalışmasının bilimsel temellerini oluşturan literatür taraması ve kuramsal çerçeve detaylı bir şekilde ele alınmıştır. Öncelikle İnsansız Hava Araçları (İHA) teknolojisinin uzaktan algılama ve gözetleme alanındaki artan rolü irdelenmiş, ardından bu platformlardan elde edilen görüntülerin işlenmesinde karşılaşılan özgün zorluklara değinilmiştir. Geleneksel bilgisayarlı görü yöntemlerinden derin öğrenme tabanlı yaklaşımlara geçiş süreci; Konvolüsyonel Sinir Ağları (CNN), nesne tespiti mimarileri ve özellikle çalışmanın ana odağını oluşturan YOLO algoritmasının evrimi bağlamında incelenmiştir. Ayrıca, havadan çekilen görüntülerde kritik bir problem olan "küçük nesne tespiti" konusu ve bu alandaki akademik boşluklar, mevcut literatür ışığında analiz edilmiştir.

1.1. İnsansız Hava Araçları ve Görüntü İşleme

İnsansız Hava Araçları (İHA), geleneksel uydu algılama yöntemlerine kıyasla sunduğu düşük maliyet, yüksek esneklik ve bulut örtüsünden etkilenmeyen yüksek çözünürlüklü veri toplama kabiliyeti sayesinde birçok sivil ve askeri uygulama için vazgeçilmez bir platform haline gelmiştir. Özellikle vahşi doğa veya engebeli arazilerde gerçekleştirilen arama-kurtarma faaliyetlerinde 'kritik zaman' faktörü hayati önem taşımaktadır. Ewers ve arkadaşları [8], 2025 yılındaki çalışmalarında bu tür senaryolarda derin öğrenme ve otonom sistemlerin zaman kazandırıcı etkisini vurgulamışlardır. Ancak, İHA'lardan elde edilen görsel verilerin analizi, yer seviyesinden alınan görüntülerle kıyaslandığında bilgisayarlı görü algoritmaları için oldukça çetin bir çalışma alanı teşkil etmektedir. Özellikle "nadir" veya kuş bakışı olarak adlandırılan dikey bakış açısı, nesne tespiti süreçlerinde özgün kısıtlamaları beraberinde getirmektedir [15].



Şekil 1.1: İHA bakış açısından arama-kurtarma operasyonu görünümü [24]


Literatürde belirtildiği üzere, yüksek irtifadan yapılan çekimlerde hedef nesne olan insanların görüntü üzerinde kapladığı alan, toplam piksel sayısının yalnızca %0,1 ile %0,2'si civarında kalmaktadır. Bu durum, nesnenin ayırt edici özneliliklerinin (yüz hatları, vücut uzunlukları vb.) kaybolmasına ve arka plan gürültüsüyle karışmasına yol açmaktadır. Ayrıca, İHA'nın uçuş irtifasının değişmesi, nesne ölçeklerinde (scale variation) devasa dalgalanmalara sebebiyet vererek tek bir modelin hem yakındaki hem de uzaktaki insanları aynı doğrulukla tespit etmesini zorlaştırmaktadır [15]. Görüntü alma dinamiklerini zorlaştıran bir diğer kritik faktör ise platformun hareketliliğidir; yüksek hızdaki uçuşlar ve ani manevralar, görüntülerde "hareket bulanıklığına" (motion blur) neden olarak detayların silinmesine yol açmaktadır. Bunun yanı sıra, doğal arazilerdeki ağaçlar, kayalar ve binaların yarattığı gölgeler gibi

karmaşık arka plan yapıları, insanların çevreyle kamufle olmasına ve yanlış negatif (missed detection) oranlarının artmasına zemin hazırlamaktadır [15].

1.2. Derin Öğrenme ve Nesne Tespiti Temelleri

Geleneksel bilgisayarlı görü yöntemlerinde kullanılan Haar-benzeri özellikler, SIFT (Ölçekten Bağımsız Öznelik Dönüşümü) veya HOG (Yönlendirilmiş Gradyan Histogramları) gibi el yapımı (handcrafted) öznelikler, İHA görüntülerindeki değişken ışık ve açı koşullarında yetersiz kalmaktadır. Bu kısıtlamalar, veriden hiyerarşik bir yapıda özellik öğrenebilen derin öğrenme tabanlı modellerin, özellikle de Evrimsel Sinir Ağlarının (CNN) nesne tespitte baskın hale gelmesine yol açmıştır [15].

1.2.1. Konvolüsyonel sinir ağları (CNN) mantığı



Şekil 1.2: Genel Konvolüsyonel Sinir Ağı (CNN) mimarisi ve katman yapısı [25]

CNN mimarileri, insan görsel sisteminden ilham alan biyolojik hiyerarşik modellerdir. Temel çalışma mantığı, görüntü üzerinde kaydırılan küçük filtreler veya çekirdekler (kernels) aracılığıyla yerel özneliklerin çıkarılmasına dayanmaktadır. Geleneksel sinir ağlarının aksine CNN'ler, görüntünün her noktasını bütünüyle ele almak yerine, hiyerarşik katmanlar aracılığıyla önce kenarlar, köşeler ve renk geçişleri gibi düşük seviyeli özellikleri; daha derin katmanlarda ise bu parçaları birleştirerek nesne formlarını ve semantik yapıları öğrenir. Bu hiyerarşik öğrenme süreci, modelin nesneyi farklı açılardan ve ışık koşullarından bağımsız olarak tanıyabilmesine olanak

tanınmaktadır. Katmanlar derinleştikçe uygulanan alt örnekleme (downsampling) işlemleri hesaplama yükünü azaltsa da, küçük nesnelere ait hassas bilgilerin kaybolması riskini de beraberinde getirmektedir [15].

1.2.2. İki aşamalı (two-stage) ve tek aşamalı (One-Stage) modeller

Derin öğrenme tabanlı nesne tespit modelleri, mimari yapılarına ve işlem önceliklerine göre temel olarak iki ana kategoriye ayrılmaktadır [15]:

1. İki Aşamalı Modeller: Bu sınıfa dahil olan Faster R-CNN, Cascade R-CNN ve Mask R-CNN gibi mimariler, tespit sürecini iki temel adıma böler. İlk aşamada, Bölge Öneri Ağı (RPN) kullanılarak görüntü içinde nesne bulunma olasılığı yüksek olan aday bölgeler (ROI) belirlenir. İkinci aşamada ise bu bölgeler sınıflandırılır ve nesne sınırları (bounding box) hassas bir şekilde düzeltilir. Bu modeller genellikle yüksek doğruluk oranlarına sahip olsalar da, her bölge önerisi için ayrı hesaplama yapılması nedeniyle işlem yükleri fazladır ve İHA üzerindeki gerçek zamanlı uygulamalarda gecikme (latency) sorunlarına yol açarlar [15].

2. Tek Aşamalı Modeller: YOLO (You Only Look Once), SSD (Single Shot Detector) ve RetinaNet gibi modeller, nesne tespitini bir regresyon problemi olarak ele alır ve görüntüyü tek bir geçişte (single pass) analiz eder. Bu yaklaşımda, bölge öneri aşaması ortadan kaldırılarak nesne konumları ve sınıf olasılıkları doğrudan tahmin edilir. Tek aşamalı modeller, iki aşamalı modellere kıyasla çok daha hızlıdır ve düşük donanım kaynağı gereksinimi sunar. Özellikle kısıtlı batarya ömrü ve işlem gücüne sahip İHA platformlarında otonom tespit yapmak için YOLO türevi hafif modeller literatürde en çok tercih edilen çözümlerdir [15].

Neticede, İHA görüntülerinden otonom insan tespiti yapabilmek için hız ve doğruluk arasındaki denge kritik bir öneme sahiptir. İki aşamalı modellerin sunduğu yüksek doğruluk, gerçek zamanlılık gereksinimi nedeniyle yerini genellikle optimize edilmiş tek aşamalı mimarilere bırakmaktadır.

1.3. YOLO Algoritması ve Gelişimi

Nesne tespiti literatüründe devrim niteliğinde bir yaklaşım sunan YOLO (You Only Look Once) algoritması, geleneksel yöntemlerin aksine nesne tespitini bir

sınıflandırma problemi yerine doğrudan bir regresyon problemi olarak ele almaktadır. Bu özgün yaklaşım, görüntünün tek bir sinir ağı değerlendirmesinden geçerek hem sınır kutularının (bounding boxes) hem de sınıf olasılıklarının eş zamanlı olarak tahmin edilmesine olanak tanımaktadır [15].

1.3.1. YOLO'nun çalışma prensibi

YOLO mimarisinin temel çalışma mekanizması, girdi görüntüsünü boyutunda bir ızgara (grid) yapısına bölmeye dayanır. Eğer bir nesnenin merkezi belirli bir ızgara hücresine düşerse, mezkur hücre o nesnenin tespit edilmesinden sorumlu hale gelir. Her hücre, nesne varlığına dair bir güven skoru (confidence score) ile birlikte sınır kutusu koordinatlarını tahmin eder. Bu güven skoru, modelin kutu içerisinde bir nesne olduğuna dair inancını ve tahmin edilen kutunun doğruluğunu yansıtmaktadır [15]. Nihai aşamada, Maksimum Olmayanı Bastırma (Non-Maximum Suppression - NMS) tekniği kullanılarak aynı nesne için üretilen mükerrer kutular elenir ve en yüksek güven puanına sahip olan sonuç çıktı olarak sunulur [15].

1.3.2. YOLOv1'den YOLOv8'e gelişim süreci YOLO algoritması, her yeni versiyonunda hız ve doğruluk dengesini optimize eden yapısal yenilikler sunmuştur:

YOLOv1: Nesne tespitini bütünsel bir boru hattı (pipeline) olarak sunan ilk sürüm olup, 45 FPS hızıyla gerçek zamanlı tespitin önünü açmıştır [15].

YOLOv2 (YOLO9000): "Anchor box" (çapa kutusu) kavramını tanıtmış ve toplu normalizasyon (batch normalization) kullanarak modelin genelleme kabiliyetini artırmıştır [15].

YOLOv3: Çok ölçekli tahmin mekanizması ve Darknet-53 omurga (backbone) mimarisi ile özellikle küçük nesnelerin tespitinde belirgin bir iyileşme sağlamıştır [15, 17].

YOLOv4: Mozaik veri artırma (mosaic data augmentation) ve CSPDarknet53 yapısı ile eğitim sürecini optimize etmiştir [15, 19].

YOLOv5: PyTorch tabanlı bir mimariye geçiş yaparak kullanıcı dostu bir yapı ve farklı donanım ihtiyaçlarına yönelik ölçeklenebilir modeller (n, s, m, l, x) sunmuştur [15, 20].

YOLOv7: Modelin yeniden parametrelendirilmesi (re-parameterization) stratejisiyle hesaplama yükünü azaltırken doğruluğu maksimize etmiştir [15, 19].

YOLOv8: Literatürdeki en güncel ve güçlü versiyonlardan biri olarak çapa kutusuz (anchor-free) bir yapıya geçmiştir. Bu sayede, nesne merkezini doğrudan tahmin ederek özellikle kümelenmiş veya küçük nesnelerin tespitinde yaşanan zorlukları minimize etmeyi hedeflemektedir [3, 15, 20].

1.3.3. Neden YOLO tercih edildi?

Proje kapsamında YOLO mimarisinin, özellikle de YOLOv8 sürümünün tercih edilmesinin arkasında yatan temel motivasyon, İHA platformlarının kısıtlı donanımsal kaynakları üzerinde gerçek zamanlı işlem yapabilme zorunluluğudur. Literatürdeki karşılaştırmalı çalışmalar incelendiğinde; Faster R-CNN gibi iki aşamalı modellerin 512x512 çözünürlükte yaklaşık 4 FPS gibi düşük hızlarda kaldığı, buna karşın YOLOv3'ün 40 FPS hızına ulaşabildiği raporlanmıştır [9, 15].

Daha güncel veriler ışığında, YOLOv8'in küçük versiyonu VisDrone veriseti üzerinde %22,8 mAP başarısı gösterirken, önerilen hafifletilmiş türevlerinin bu değeri koruyarak çok daha düşük parametre sayısı ile çalışabildiği görülmüştür. SSD (Single Shot Detector) modeli ise sık katman yapısı nedeniyle küçük nesne tespitinde YOLO'nun gerisinde kalmaktadır. Dolayısıyla, hem hız hem de doğruluk parametrelerini tek bir çatı altında optimize edebilen YOLOv8, otonom İHA operasyonları için en rasyonel mühendislik tercihi olarak öne çıkmaktadır [3, 9, 15, 23].

1.4. Küçük Nesne Tespiti (Small Object Detection) Problemi

Küçük nesne tespiti, derin öğrenme tabanlı bilgisayarlı görü alanında "çözülmesi en güç problemlerden biri" olarak tanımlanmaktadır. MS-COCO metriklerine göre 32x32 pikselden küçük olan nesneler bu kategoriye dahil edilmektedir. İHA görüntülerinde ise yüksek irtifa ve geniş bakış açısı nedeniyle insanların kapladığı alan, toplam piksel

sayısının sadece %0,1 ile %0,2'si kadardır [6, 9, 15, 16]. Nesnelerin bu denli düşük çözünürlükle temsil edilmesi sorununu aşmak adına, literatürde çeşitli görüntü iyileştirme (image enhancement) teknikleri Tekin ve Bozkır [14] tarafından incelenmiş; ayrıca süper çözünürlük (super-resolution) yöntemlerinin insan tespiti üzerindeki olumlu etkileri Agarwal ve arkadaşları [1] tarafından ortaya konmuştur.

1.4.1. Literatürdeki temel zorluklar

Literatür taraması, küçük nesne tespitinde yaşanan başarısızlıkların temel nedenlerini şu başlıklar altında toplamaktadır:

1. **Özellik Kaybı (Feature Loss):** Standart CNN mimarileri, görüntüyü arka arkaya alt örnekleme (downsampling) işlemlerine tabi tutar. Bu süreçte, küçük nesnelere ait zaten kısıtlı olan mekansal bilgiler, derin katmanlara ulaşıldığında tamamen silinebilmekte veya arka plan gürültüsüyle karışabilmektedir [15, 21].
2. **Düşük Çözünürlük ve Bulanıklık:** İHA'nın hareketliliği sonucu oluşan hareket bulanıklığı (motion blur) ve düşük ışık koşulları, küçük nesnelerin kenar hatlarının belirsizleşmesine yol açarak modelin öznetelik çıkarımı yapmasını engellemektedir [13].
3. **Kümelenme (Clustering) ve Örtüşme:** İnsanların kalabalık alanlarda bir arada bulunması, sınır kutularının birbirine çok yakın olmasına veya iç içe geçmesine neden olur. Bu durum, geleneksel NMS algoritmalarının gerçek nesneleri yanlışlıkla "mükerrer" olarak algılayıp silmesine (false negative) sebebiyet verir [20].

1.4.2. VisDrone Veriseti ve Önemi

İHA odaklı nesne tespiti çalışmalarında altın standart olarak kabul edilen VisDrone makalesi, bu zorlukları somut verilerle ortaya koymaktadır. Bu verisetinde yer alan nesnelerin %75'inden fazlası görüntünün toplam alanının %0,1'inden daha azını kaplamaktadır. VisDrone üzerindeki testlerde, standart modellerin performansının yer seviyesindeki görüntülere kıyasla dramatik şekilde düştüğü gözlemlenmiştir. Projemizde geliştirilmesi planlanan sistemin, bu literatür verilerini baz alarak, P2 tespit katmanı ve SPD-Conv gibi modüllerle küçük nesne hassasiyetini artırması hedeflenmektedir [15, 18, 20, 23].

2. MATERYAL VE YÖNTEM

İnsansız Hava Araçları (İHA) görüntülerinden gerçek zamanlı insan tespiti gerçekleştirmeyi amaçlayan bu çalışma, yüksek çözünürlüklü verilerin kısıtlı donanım kaynakları üzerinde en verimli şekilde işlenmesini temel alan bir metodoloji üzerine inşa edilecektir. Bu bölümde, model eğitiminde kullanılacak verilerin nitelikleri, küçük nesne tespiti problemini aşmak için uygulanacak stratejik ön işlemler ve seçilen YOLOv8 mimarisinin teknik detayları ile eğitim planı aktarılacaktır.

2.1. Veri Seti (VisDrone2019-DET)



Şekil 2.1: VisDrone2019-DET veri seti kullanılarak oluşturulan örnek etiketli görüntüler [23]

Proje kapsamında hedeflenen otonom tespit yeteneğinin geliştirilmesi için literatürde İHA tabanlı nesne tespiti çalışmalarında "altın standart" kabul edilen VisDrone2019-DET veri setinden faydalanılacaktır. Bu kapsamlı benchmark; Çin'in farklı coğrafi özelliklere sahip 14 şehrinde, çeşitli İHA platformları ve kameraları kullanarak

kaydedilen 263 video klibi ve 10.209 statik görüntüden teşekkül etmektedir. Veri setindeki görüntüler 2000x1500 piksele varan yüksek çözünürlük değerlerine sahip olup, kentsel ve kırsal alanlardaki değişken hava ve ışık koşullarını yansıtmaktadır [23].

Veri setinde yer alan nesnelerin yaklaşık %75'inden fazlasının 32x32 pikselden küçük olması, mezkur çalışmanın odak noktası olan "küçük nesne tespiti" (small object detection) problemi için oldukça zorlu ve bir o kadar da öğretici bir zemin hazırlamaktadır. Veri seti; yaya, insan, bisiklet, otomobil, kamyonet, kamyon, üç tekerlekli araç, tenteli üç tekerlekli araç, otobüs ve motosiklet olmak üzere toplam 10 farklı nesne sınıfını ihtiva etmektedir [20, 23].


Planlanan ön işlemler şöyledir:

Sınıf Birleştirme: Projenin birincil gayesi arama-kurtarma odaklı insan tespiti olduğundan, görsel olarak birbirine son derece yakın öznitelikler taşıyan "pedestrian" (yaya) ve "person" (insan) sınıflarının tek bir "insan" etiketi altında birleştirilmesi hedeflenmektedir [23]. Bu sayede modelin sınıfsal karmaşıklığı azaltılarak, hedef nesne üzerindeki özgül ağırlığı artırılacaktır.

Slicing Aided Hyper Inference (SAHI) Entegrasyonu: İHA görüntülerinin yüksek çözünürlüklü yapısı, standart derin öğrenme modellerinin girdi boyutlarına (örn. 640x640) indirgendiğinde küçük nesnelerde ciddi öznitelik kaybına yol açmaktadır [2, 9]. Bu kaybın önüne geçmek adına, görüntülerin belirli piksel aralıklarıyla örtüşen dilimlere (slices) bölünmesi ve her dilimin bağımsız olarak analiz edilmesi prensibine dayanan SAHI algoritmasının uygulanması planlanmaktadır [2, 9].

Veri Artırma (Data Augmentation): Modelin farklı ışık seviyelerinde ve bakış açılarında genelleme yeteneğini pekiştirmek için eğitim aşamasında mozaikleme (mosaic), MixUp ve rastgele döndürme gibi tekniklerin kullanılması planlanmaktadır [13, 20, 19].

2.2. Kullanılacak Model Mimarisi (YOLOv8)




sayesinde, özellikle İHA görüntülerinde karşılaşılan değişken ölçekli ve küçük insan silüetlerinin tespitinde daha yüksek bir esneklik sunmaktadır [20].

YOLOv8-Nano (n) ve Small (s) Seçim Gerekçesi: İHA operasyonlarında saniyedeki görüntü işleme hızı (FPS) ve enerji verimliliği kritik birer parametredir [3, 13]. Bu doğrultuda, yaklaşık 3,2 milyon parametre barındıran YOLOv8-Nano veya 11,1 milyon parametreye sahip YOLOv8-Small modellerinden birinin tercih edilmesi planlanmaktadır [3, 20]. Bu hafifletilmiş mimarilerin seçilme nedenleri şunlardır:

Donanım Kısıtları: Sistemin İHA üzerindeki kısıtlı işlem gücüne sahip gömülü kartlarda (Raspberry Pi, Jetson Nano vb.) düşük gecikme ile çalışabilmesi amaçlanmaktadır [13].

Gerçek Zamanlılık: Afet sonrası müdahale gibi zamanla yarışılan senaryolarda en az 30 FPS hızına ulaşılması hedeflenmekte, bu da ancak düşük parametrelili modellerle mümkün görülmektedir [3, 11].

2.3. Eğitim Stratejisi ve Donanım



Şekil 2.3: Önerilen sistemin genel çalışma akış şeması

Eğitim sürecinde izlenecek temel stratejiler aşağıda maddelenmiştir:

Aktarımlı Öğrenme (Transfer Learning): Modelin sıfırdan eğitilmesinin yaratacağı devasa hesapsal yükü ve zaman maliyetini minimize etmek amacıyla, MS-COCO veri setinde önceden eğitilmiş ağırlıkların (pre-trained weights) başlangıç noktası olarak kullanılması planlanmaktadır [5, 9, 13]. Bu yöntemin, modelin düşük seviyeli görsel öz nitelikleri (kenarlar, renk geçişleri vb.) halihazırda öğrenmiş olmasından faydalanarak VisDrone veri setine daha hızlı ve stabil bir şekilde adapte olmasını sağlaması beklenmektedir [5, 9, 13].

Hiperparametre Optimizasyonu: Eğitim sırasında öğrenme oranı (learning rate) ve yığın boyutu (batch size) gibi kritik değerlerin, modelin kayıp (loss) değerini stabilize edecek şekilde optimize edilmesi hedeflenmektedir [17, 22].


2.4. Başarı Ölçütleri (Metrikler)

Geliştirilecek sistemin başarısı, literatürde kabul görmüş nesne tespiti performans metrikleri üzerinden akademik bir titizlikle değerlendirilecektir [17, 21]. Bu bağlamda şu kavramların hesaplanması planlanmaktadır:

Kesinlik (Precision): Model tarafından "insan" olarak etiketlenen bölgelerin ne kadarının gerçekte insan olduğunu ifade eder; yanlış pozitif (false positive) oranını denetlemek için kullanılacaktır [4, 13, 21].

Duyarlılık (Recall): Sahadaki gerçek insanların ne kadarının model tarafından başarıyla yakalanabildiğini gösterir; arama-kurtarma operasyonlarında bir mağdurun gözden kaçırılması hayati risk taşıdığından bu metriğin maksimize edilmesi hedeflenmektedir [10, 13, 21].

mAP@50 (Mean Average Precision): Kesinlik-Duyarlılık eğrisi altında kalan alanın, Kesişim bölü Birleşim (IoU) eşiği 0,50 olduğunda hesaplanan ortalama değeridir. Bu değer, projenin en temel doğruluk göstergesi olarak baz alınacaktır [13, 17, 21].

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}} = \frac{\text{Intersection}}{\text{Ground truth box} + \text{Detected box} - \text{Intersection}}$$


Şekil 2.4: Intersection over Union (IoU) hesaplama mantığı [27]

Neticede, planlanan bu metodolojik boru hattı ile İHA'dan gelen ham görsel verilerin, manuel müdahaleye ihtiyaç duymaksızın yüksek bir süratle analiz edilmesi ve kurtarma ekiplerine kritik zaman kazandırılması amaçlanmaktadır.

Bu sistemi, uçsuz bucaksız bir orman arazisinde kaybolmuş birini arayan bir gözlemcinin elindeki sihirli bir büyütece benzetebiliriz. Standart yöntemler araziye bütünüyle tarayıp yorulurken (insan gözü veya hantal modeller), geliştirmeyi planladığımız sistem araziye küçük dilimlere bölüp her birini akıllı ve hızlı bir şekilde süzerek (SAHI ve YOLOv8), en küçük insan silüetini dahi bir yaşam belirtisi olarak saniyeler içinde raporlayabilecektir.

3. BEKLENEN SONUÇLAR VE TARTIŞMA

Projenin ikinci aşamasında gerçekleştirilecek olan deneysel süreçler, eğitim aşamasında elde edilen teorik kazanımların reel saha koşullarında ne ölçüde karşılık bulduğunu belirlemek amacıyla yürütülecektir. Henüz uygulama safhasına geçilmemiş olması hasebiyle, bu bölümde literatür verileri ve seçilen modelin (YOLOv8) karakteristik özellikleri ışığında öngörülen performans çıktıları ve test metodolojisi ele alınacaktır.

3.1. Test Senaryoları

Geliştirilmesi hedeflenen sistemin başarısı, yalnızca kontrollü laboratuvar ortamlarında değil, afet bölgelerinin kaotik ve değişken yapısında göstereceği dayanıklılıkla ölçülecektir. Bu doğrultuda model, VisDrone test setinde yer alan farklı irtifa ve bakış açılarına sahip görüntüler üzerinden kapsamlı bir sınava tabi tutulacaktır [9]. Planlanan test senaryoları şu başlıklar altında toplanmaktadır:

Değişken İrtifa ve Ölçek Varyasyonları: İHA'nın 10 metreden 120 metreye kadar değişen irtifalarındaki insan silüetlerinin tespit başarısı analiz edilecektir. Özellikle yüksek irtifada piksellerin kaybolduğu (küçük nesne problemi) senaryolarda SAHI modülünün katkısı irdelenecektir[9, 15].

Aydınlatma ve Hava Koşulları: Afet sonrası müdahalenin günün her saatinde sürmesi zorunluluğu nedeniyle; tam aydınlık, alacakaranlık ve düşük ışıklı gece çekimleri üzerinde performans ölçümü yapılacaktır[9, 15].

Karmaşık Arka Plan ve Yoğunluk: İnsanların binaların gölgesinde kaldığı, ağaçlar tarafından kısmen perdelenildiği veya kalabalık gruplar halinde bulunduğu (clustering) zorlu karelerde modelin ayırt ediciliği test edilecektir [9].

3.2. Beklenen Performans Analizi

Literatürdeki güncel çalışmalar, özellikle YOLOv8 ve türevlerinin VisDrone gibi küçük nesne yoğunluklu veri setlerinde umut verici sonuçlar sunduğunu

göstermektedir [9]. Benzer mimariler üzerine inşa edilen çalışmalara bakıldığında (Örn: [9, 15]), YOLOv8-Nano veya Small modellerinden %25 ile %45 arasında bir mAP@50 (Mean Average Precision) değeri elde edilmesi öngörülmektedir. Hız tarafında ise, ile desteklenen sistemin, gömülü donanımlar üzerinde 30 FPS (Frames Per Second) barajını aşarak gerçek zamanlı tespit kabiliyetini kanıtlaması beklenmektedir [9].

Olası Hata Durumları ve Çözüm Yaklaşımları: Tespit sürecinde yaşanabilecek en kritik sorunlardan biri, insan dışındaki nesnelerin (kayalar, çöp yığınları veya bitki örtüsü) yanlışlıkla insan olarak etiketlenmesidir (False Positive). Literatürde bu durumun özellikle düşük kontrastlı sahnelerde arttığı raporlanmıştır [9]. Bu tür hataları minimize etmek adına, güven eşiği (confidence threshold) değerlerinin dinamik olarak ayarlanması ve modelin eğitiminde "negatif örnek" (background-only images) kullanımının artırılması planlanmaktadır. Ayrıca, ardışık video kareleri arasında zamansal tutarlılık kontrolü yapılarak anlık hatalı tespitlerin elenmesi hedeflenmektedir.

3.3. Karşılaştırma Planı

Elde edilecek sonuçların akademik geçerliliğini sağlamak amacıyla sistem, geleneksel ve güncel diğer tespit modelleriyle kıyaslanacaktır. Bu kıyaslamada temel olarak şu modeller baz alınacaktır:

Faster R-CNN (İki Aşamalı): Yüksek doğruluk sunmasına rağmen İHA platformlarında saniyede 4-7 FPS gibi düşük hızlarda kalması beklenen bu modelle "doğruluk" kıyaslaması yapılacaktır [9, 15].

SSD (Tek Aşamalı): Sığ katman yapısı nedeniyle küçük nesne tespitinde YOLOv8'in gerisinde kalacağı ve yeterince iyi olmayacağı öngörülen bu modelle "hız ve verimlilik" analizi gerçekleştirilecektir [9].

Değerlendirme Kriterleri: Model eğitildiğinde, eğitim süreci boyunca kaydedilen Loss (Kayıp) ve mAP eğrileri titizlikle incelenecektir. Başarı; Loss eğrisinin stabil bir şekilde azaldığı ve mAP değerinin hedeflenen seviyelerde doyuma ulaştığı noktada teyit edilecektir. Neticede, hem arama-kurtarma operasyonlarının hayati hız

gereksinimini karřılayan (yüksek FPS) hem de mađdurları gözden kaçırmayan (yüksek Recall) optimum dengenin kurulması çalışmanın nihai başarı kriteri olarak yorumlanacaktır.

4. SONUÇ VE ÖNERİLER

Afet sonrası yürütülen arama-kurtarma faaliyetlerinde saniyelerin dahi hayati bir kıymete sahip olması, İnsansız Hava Araçlarının (İHA) bu süreçteki rolünü vazgeçilmez kılmaktadır [13]. Geleneksel yöntemlerle taramanın riskli veya imkânsız olduğu sarp arazilerde, İHA'lar otonom birer gözlemci olarak kritik veri akışı sağlamaktadır [3, 9]. Bu çalışmada temel yöntem olarak benimsenen YOLOv8 mimarisi, nesne tespiti literatüründeki en güncel yaklaşımlardan biri olarak hem hız hem de doğruluk parametrelerini eş zamanlı optimize edebilmektedir [9, 13]. Özellikle kısıtlı işlem gücüne sahip hava platformlarında gerçek zamanlı çıkarım yapabilmesi, YOLOv8'i zamanla yarışılan afet senaryoları için en rasyonel mühendislik çözümü haline getirmektedir [10, 13].

Projenin araştırma ve hazırlık aşamasını kapsayan bu dönemde, İHA görüntülerinden küçük nesne tespiti yapılmasına dair kapsamlı bir literatür taraması gerçekleştirilerek güncel metodolojiler analiz edilmiştir [9, 13]. Bu doğrultuda, çalışmanın odak noktası olan küçük nesne tespiti problemine en uygun yanıtı veren VisDrone2019-DET veri seti üzerinde karar kılınmış ve gerekli sınıf birleştirme gibi ön işlem adımları planlanmıştır [23]. Sistemin omurgasını oluşturacak olan YOLOv8 modelinin teorik çerçevesi çizilmiş ve donanımsal kısıtlar göz önüne alınarak Nano ve Small modelleri üzerinden bir yol haritası belirlenmiştir [9, 13].

Uygulama safhasını içeren ikinci dönemde, belirlenen bu teorik altyapının hayata geçirilmesi planlanmaktadır. İlk adım olarak, Google Colab üzerindeki GPU birimleri kullanılarak modelin eğitimi gerçekleştirilecek ve başarı metriklerini maksimize etmek adına hiperparametre optimizasyonuna gidilecektir. Statik görüntülerdeki başarı teyit edildikten sonra, sistemin dinamik saha koşullarındaki dayanıklılığını ölçmek amacıyla gerçek zamanlı video testleri yürütülecektir [9]. Özellikle yüksek irtifadaki çekimlerde insanların çok küçük bir piksel alanı kaplamasından doğan "kaybolma" etkisini minimize etmek için SAHI (Slicing Aided Hyper Inference) tekniğinin sisteme entegre edilmesi hedeflenmektedir [2]. Bu teknik, görüntüyü akıllı dilimlere bölerek

modelin en küçük detayları dahi yakalamasına olanak tanıyacak bir vizyon katacaktır [2]. Nihai aşamada ise, tüm bu algoritmik sürecin sahadaki ekipler tarafından pratik bir şekilde kullanılabilmesi için sistem bir grafik kullanıcı arayüzü (GUI) ile taçlandırılacaktır [7, 11].

Neticede, bu proje tamamlandığında, arama-kurtarma ekiplerine hız kazandıracak, insan gözünün yorgunluk ve dikkat dağınıklığı gibi zaaflarından arındırılmış otonom bir sistem ortaya çıkacaktır.

KAYNAKLAR

- [1] Agarwal, A., Ratha, N., Vatsa, M., & Singh, R. (2021). "Impact of Super-Resolution and Human Identification in Drone Surveillance." 2021 IEEE International Workshop on Information Forensics and Security (WIFS), Montpellier, France.
- [2] Akyon, F. C., Altinuc, S. O., & Temizel, A. (2022). "Slicing Aided Hyper Inference and Fine-Tuning for Small Object Detection." 2022 IEEE International Conference on Image Processing (ICIP), Bordeaux, France, pp. 966-970.
- [3] And, J., Lee, D. H., Putro, M. D., & Kim, B. W. (2024). "DCE-YOLOv8: Lightweight and Accurate Object Detection for Drone Vision." IEEE Access, 12, 170898-170912.
- [4] Bejiga, M. B., Zeggada, A., & Melgani, F. (2017). "Convolutional Neural Networks for Near Real-Time Object Detection from UAV Imagery in Avalanche Search and Rescue Operations." 2017 IEEE International Geoscience and Remote Sensing Symposium (IGARSS), Fort Worth, TX, USA.
- [5] Božić-Štulić, D., Marušić, Ž., & Gotovac, S. (2019). "Deep Learning Approach in Aerial Imagery for Supporting Land Search and Rescue Missions." International Journal of Computer Vision, 127, 1256–1278.
- [6] Dousai, N. M. K., & Loncaric, S. (2022). "Detecting Humans in Search and Rescue Operations Based on Ensemble Learning." IEEE Access, 10, 26481-26492.
- [7] Elmas, E. E., & Alkan, M. (2022). "Detection and Tracking of Moving Objects with Unmanned Aerial Vehicles." Gazi University Journal of Science Part C: Design and Technology, 10(4), 1111-1126.
- [8] Ewers, J. H., Anderson, D., & Thomson, D. (2025). "Deep Reinforcement Learning for Time-Critical Wilderness Search and Rescue with Drones." Frontiers in Robotics and AI, 11, 1527095.
- [9] Liu, Y., Sun, P., Wergeles, N., & Shang, Y. (2021). "A Survey and Performance Evaluation of Deep Learning Methods for Small Object Detection." Expert Systems with Applications, 172, 114602.
- [10] Mittal, P., Singh, R., & Sharma, A. (2020). "Deep learning-based object detection in low-altitude UAV datasets: A survey." Image and Vision Computing, 104, 104046.

- [11] Orhan, H., & Arıcı, F. N. (2024). "Farklı YOLO Algoritmalarının Gerçek Zamanlı İHA Tespitine Etkileri ve Karşılaştırmalı Analizi." *Gazi Üniversitesi Fen Bilimleri Dergisi Part C: Tasarım ve Teknoloji*, 12(2), 691-706.
- [12] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). "You Only Look Once: Unified, Real-Time Object Detection." 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, pp. 779-788.
- [13] Simões, D. P., Oliveira, H. C., Marsico, S., Souza, J. R., & Barbosa, L. A. (2025). "Human detection in UAV imagery using deep learning: a review." *Neural Computing and Applications*, 37, 18109-18150.
- [14] Tekin, A., & Bozkır, A. S. (2024). "Enhance or Leave It: An Investigation of the Image Enhancement in Small Object Detection in Aerial Images." *Journal of the Institute of Science and Technology*, 14(1), 8-17.
- [15] Toby, T., Gopalakrishnan, U., & Rao, S. N. (2022). "A Survey of Deep Learning Techniques Based On Drone Images For The Search And Rescue Of Victims From Collapsed Structures." 2022 IEEE 19th India Council International Conference (INDICON), Kochi, India.
- [16] Tong, K., Wu, Y., & Zhou, F. (2020). "Recent advances in small object detection based on deep learning: A review." *Image and Vision Computing*, 97, 103910.
- [17] Usta, A., & Arserim, M. A. (2023). "İnsansız hava aracından çekilen videolar kullanılarak derin öğrenme yaklaşımı ile nesne tespiti." *Dicle Üniversitesi Mühendislik Fakültesi Dergisi*, 14(1), 9-15.
- [18] Wang, P., & Zhao, J. (2025). "SOD-YOLO: Enhancing YOLO-Based Detection of Small Objects in UAV Imagery." *arXiv preprint arXiv:2507.12727*.
- [19] Wang, X., He, N., Hong, C., Wang, Q., & Chen, M. (2023). "Improved YOLO based UAV aerial photography object detection algorithm." *Image and Vision Computing*, 135, 104697.
- [20] Zhang, H., Sun, W., Sun, C., He, R., & Zhang, Y. (2024). "HSP-YOLOv8: UAV Aerial Photography Small Target Detection Algorithm." *Drones*, 8(9), 453.
- [21] Zhao, X., Yang, Z., & Zhao, H. (2025). "DCS-YOLOv8: A Lightweight Context-Aware Network for Small Object Detection in UAV Remote Sensing Imagery." *Remote Sensing*, 17(17), 2989.
- [22] Zhu, C., He, Y., & Savvides, M. (2019). "Feature Selective Anchor-Free Module for Single-Shot Object Detection." 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, pp. 840-849.

- [23] Zhu, P., Wen, L., Du, D., Bian, X., Fan, H., Hu, Q., & Ling, H. (2018). "Vision Meets Drones: A Challenge." arXiv preprint arXiv:1804.07437.
- [24] DSLRPros, "Drone Scanning a Collapsed Building with Thermal Imaging," DSLRPros Blog, [Çevrimiçi]. Erişim Adresi: https://www.dslrpros.com/cdn/shop/articles/drone_scanning_a_collapsed_building_with_thermal_imaging.jpg. [Erişim Tarihi: 31 Aralık 2025].
- [25] V. Lomonaco, "A complete example of a CNN architecture with seven layer (LeNet7)," ResearchGate, [Çevrimiçi]. Erişim Adresi: <https://www.researchgate.net/profile/Vincenzo-Lomonaco/publication/285583518/figure/fig27/AS:782277965516804@1563521009961/A-complete-example-of-a-CNN-architecture-with-seven-layer-or-commonly-called-LeNet7-from.ppm>. [Erişim Tarihi: 31 Aralık 2025].
- [26] RangeKing, "Brief summary of YOLOv8 model structure," GitHub Repository - Ultralytics/Ultralytics, Issue #189, [Çevrimiçi]. Erişim Adresi: <https://github.com/ultralytics/ultralytics/issues/189>. [Erişim Tarihi: 31 Aralık 2025].
- [27] Baeldung, "Intersection over Union (IoU) for Object Detection," Baeldung Computer Science, [Çevrimiçi]. Erişim Adresi: <https://www.baeldung.com/wp-content/uploads/sites/4/2022/04/fig1.png>. [Erişim Tarihi: 1 Ocak 2026].

ÖZGEÇMİŞ

Yunus Emre Arı 2003'te İstanbul'da doğdu. Lise öğrenimini Dede Korkut Anadolu Lisesi'nde tamamladı. 2021 yılında girdiği Yıldız Teknik Üniversitesi Makine Mühendisliği Bölümü'nden 2023 yılında yatay geçişle Kocaeli Üniversitesi Bilgisayar Mühendisliği Bölümü'ne geçti ve bu bölümde eğitimine devam etmektedir.